

Identification *in silico* d'une séquence codante

(Durée : 30 minutes, sur 5 points – avec un barème sur...plus de points!)

Lors de l'annotation d'un génome, on analyse le brin codant (non transcrit) de l'ADN, orienté de 5' vers 3'. L'identification d'une Séquence Codante (CDS) repose sur la détection d'une Phase Ouverte de Lecture (ORF).

Celle-ci débute par un codon d'initiation **ATG** et s'achève au premier codon de terminaison rencontré (pour simplifier ici, on se limitera au codon stop **TAA**) situé dans le même cadre de lecture (c'est-à-dire que le nombre de nucléotides les séparant doit être un multiple de 3).

On travaillera sur la séquence suivante :

```
brin_codant = "GGCATGGTCAGTCGCTACTAATGC"
```

Question 1 : Repérage d'un codon

Écrivez une fonction `cherche_codon(adn, codon)` qui parcourt la chaîne de caractères `adn` et renvoie l'indice de la première occurrence du codon cherché. Si le codon n'est pas présent, la fonction devra renvoyer `False`.

NB : cette question sur 2 points est identique (à l'habillage près) à un exercice vu en TP.

Question 2 : Application

En utilisant la fonction définie à la question précédente, écrivez les deux commandes Python permettant de trouver respectivement l'indice du codon start (ATG) et l'indice du codon stop (TAA) dans la séquence `brin_codant`. Précisez également les valeurs numériques qui seront renvoyées par l'exécution de ces deux commandes.

Question 3 : Extraction de la CDS

En utilisant les fonctions précédentes et le "slicing" de chaînes, écrivez une fonction `extraction_cds(adn)` qui renvoie la séquence d'ADN de l'ORF complète, incluant le codon start et le codon stop.

